

# Синолитические сети в классификации мозговой активности

Власенко Даниил

Научные руководители: Заикин Алесей, Захаров Денис Геннадьевич

19 февраля 2023 г.

# Содержание

- 1 Введение
- 2 Синолитические сети
- 3 Понижение размерности
- 4 Алгоритм
- 5 Результаты

# фМРТ

## Определение

*Функциональная магнитно-резонансная томография или фМРТ — разновидность магнитно-резонансной томографии, которая проводится с целью измерения изменений в токе крови, вызванных нейронной активностью головного мозга.*



Рис.: фМРТ сканер.

# фМРТ




Рис.: МРТ скан.

# Цель работы

Будем считать, что мозг может функционировать в двух режимах.

## Цель работы

*Реализация и тестирование нового метода классификации режимов мозговой активности на основе фМРТ данных.*

# Классификация

## Вероятностная постановка задачи классификации

Пусть есть с.в.  $\xi : \Omega \rightarrow X$  и с.в.  $\eta : \Omega \rightarrow Y$ . Рассмотрим с.в.  $(\xi, \eta) : \Omega \rightarrow (X, Y)$  с распределением  $p(x, y)$ .

Задача классификации сводится к оценке  $p(y|x)$  по выборке  $(\tilde{X}, \tilde{Y}) = \{(x_n, y_n)\}_n$ .

## Алгоритмическая постановка задачи классификации

Пусть  $X$  — множество описаний объектов,  $Y$  — множество номеров классов. Существует функция  $f : X \rightarrow Y$ , значения которой известны только на объектах выборки  $(\tilde{X}, \tilde{Y}) = \{(x_n, y_n)\}_n$ .

Требуется построить алгоритм-оценку  $\hat{f} : X \rightarrow Y$ .

# Векторизация

NiBabel — библиотека предоставляющая возможность читать различные форматы файлов нейровизуализации.





Рис.: Векторизация фМРТ данных.

# Основная идея (Zaikin Alexey 2022)



**Рис.:** Классификация на основе построения графов отражающих входные данные.



# Обозначения

Пусть  $X$  — множество фМРТ, а  $Y = \{I, II\}$  — режимы когнитивной активности.  $(\tilde{X}, \tilde{Y}) = \{(x_n, y_n)\}_n$  — конечная выборка из  $(X, Y)$ .

$x_k \in X$  конвертируется в массив  $a^k$ , на основе которого строится граф  $g_k = (V_k, E_k, R_k, W_k)$ , где

- $V_k = \{v_i^k\}_i$  — множество вершин,
- $E_k = \{e_{ij}^k\}_{ij}$  — множество неориентированных ребер,
- $R_k = \{r_i^k\}_i$  — множество значений вершин,
- $W_k = \{w_{ij}^k\}_{ij}$  — множество весов ребер,
- $v_i^k$  — вершина отражающая область мозга  $i$ ,
- $e_{ij}^k$  — ребро отражающее связь между областями  $i$  и  $j$ ,
- $r_i^k$  — значение вершины  $v_i^k$ ,
- $w_{ij}^k$  — вес ребра  $e_{ij}^k$ .

# Подсчет весов ребер $w_{ij}^k$

Вероятностное определение  $w_{ij}^k$

$$w_{ij}^k = P(y_k = II | r_i^k, r_j^k) - P(y_k = I | r_i^k, r_j^k)$$

Пусть  $Cl_{ij} : \{y_k | (r_i^k, r_j^k), \{(r_i^n, r_j^n)\}_n, \{y_n\}_n\}_k \rightarrow [0, 1]$  — вероятностный классификатор.

Алгоритмическое определение  $w_{ij}^k$

$$w_{ij}^k = Cl_{ij}(y_k = II | (r_i^k, r_j^k), \{(r_i^n, r_j^n)\}_n, \{y_n\}_n) - \\ - Cl_{ij}(y_k = I | (r_i^k, r_j^k), \{(r_i^n, r_j^n)\}_n, \{y_n\}_n)$$




Рис.: Эмпирическая плотность распределения  $(r_i, r_j)$  для двух режимов, вычисленная по  $\{(r_i^n, r_j^n)\}_n$

# Увеличение размеров вокселя

Увеличение размера шага решетки фМРТ в  $n$  раз уменьшает число вокселей в  $n^3$  раза.




Рис.: Воксель 2 мм<sup>3</sup>




Рис.: Воксель 4 мм<sup>3</sup>




Рис.: Воксель 10 мм<sup>3</sup>

# Понижение размерности по времени

Пусть  $T$  — некоторая статистика,

$$a^{kT} = T(a^k),$$

т.е. для  $\forall x, y, z$

$$a_{xyz}^{kT} = T(\{a_{xyzt}^k : \forall t\}).$$




Рис.: Значения вокселя.

# Смена структуры графа

Переход от полного графа к графу-решетке снижает время вычисления и требуемую память с  $O(n^2)$  до  $O(n)$ , где  $n$  — число вершин графа.




Рис.: Переход от полного графа к графу-решетке.

# Обучение модели

Входные данные:

- выборка  $(\tilde{X}, \tilde{Y})$ ,
- новый размер шага решетки фМРТ  $s$ ,
- статистики вокселей  $\{T_r\}_r$ ,
- минимальное значение вершины  $r$ , для которого инцидентные с ним ребра не удаляются из графа,
- минимальное абсолютное значение ребра  $w$ , для которого ребро не удаляется из графа,
- статистики графов  $\{P_u\}_u$ , на которых будет учиться модель.

# Обучение модели

Алгоритм:

- 1 изменение шага решетки фМРТ на  $s$  для  $\forall x_n \in \tilde{X}$ ;
- 2 построение  $\{a^n\}_n$ ;
- 3 вычисление  $\{\{a^{nT_p}\}_p\}_n$ ;
- 4 обучение  $\{Cl_{ij}\}_{ij}$  на выборке  $(\{\{a^{nT_p}\}_p\}_n, \tilde{Y})$ ;
- 5 подсчет  $\{W_n\}_n = \{\{w_{ij}^n\}_{ij}\}_n$  с помощью  $\{Cl_{ij}\}_{ij}$  и  $\{\{a^{nT_p}\}_p\}_n$ ;
- 6 построение графов  $\{g_n\}_n$  с помощью  $\{W_n\}_n$  и  $\{\{a^{nT_p}\}_p\}_n$ ;
- 7 удаление ребер  $\{e_{ij}^n : r_i^n < r | r_j^n < r | w_{ij}^n < w\}_{ij}$  для  $\forall g_n$ ;
- 8 вычисление  $\{\{p_u^n\}_u\}_n = \{\{P_u(g_n)\}_u\}_n$ ;
- 9 обучение  $Cl$  на выборке  $\{\{p_u^n\}_u\}_n$ .



# Классификация

Входные данные:

- фМРТ  $x_k$ .

Алгоритм:

- 1 изменение шага фМРТ  $x_k$  решетки на  $s$ ;
- 2 построение  $a^k$ ;
- 3 вычисление  $\{a^{kT_p}\}_p$ ;
- 4 подсчет  $W_k = \{w_{ij}^k\}_{ij}$  с помощью  $\{Cl_{ij}\}_{ij}$  и  $\{a^{kT_p}\}_p$ ;
- 5 построение графа  $g_k$  с помощью  $W_k$  и  $\{a^{kT_p}\}_p$ ;
- 6 удаление из  $g_k$  ребер  $\{e_{ij}^k : r_i^k < r | r_j^k < r | w_{ij}^k < w\}_{ij}$ ;
- 7 вычисление  $\{p_u^k\}_u = \{P_u(g)\}_u$ ;
- 8 классификация  $\{p_u^k\}_u$  с помощью  $Cl$ .

# Данные





Рис.: Разделение выборки.

Рис.: Наблюдение или воображение объекта.

# Точность классификации, %

<i>mean</i>	<i>median</i>	<i>max</i>	<i>min</i>	<i>max – min</i>
100	100	95.7	97.1	90

<i>q<sub>0.9</sub></i>	<i>q<sub>0.1</sub></i>	<i>q<sub>0.9</sub> – q<sub>0.1</sub></i>
98.6	100	88.6