

Синолитические сети в классификации мозговой активности

Власенко Даниил

Научные руководители: Заикин Алесей, Захаров Денис Геннадьевич

18 февраля 2023 г.

Содержание

- 1 Введение
- 2 Синолитические сети
- 3 Понижение размерности
- 4 Алгоритм
- 5 Результаты

фМРТ

Определение

Функциональная магнитно-резонансная томография или фМРТ — разновидность магнитно-резонансной томографии, которая проводится с целью измерения изменений в токе крови, вызванных нейронной активностью головного или спинного мозга.




Рис.: фМРТ сканер.

фМРТ




Рис.: МРТ скан.

Цель работы

Будем считать, что мозг может функционировать в двух режимах.

Цель работы

Реализация и тестирование нового метода классификации режимов мозговой активности на основе фМРТ данных.

Классификация

Вероятностная постановка задачи классификации

Пусть есть с.в. $\xi : \Omega \rightarrow X$ и с.в. $\eta : \Omega \rightarrow Y$. Рассмотрим с.в. $(\xi, \eta) : \Omega \rightarrow (X, Y)$ с распределением $p(x, y)$.

Задача классификации сводится оценке $p(y|x)$ по выборке $(\tilde{X}, \tilde{Y}) = \{(x_k, y_k), k = 1, \dots, N\}$

Алгоритмическая постановка задачи классификации

Пусть X — множество описаний объектов, Y — множество номеров классов. Существует функция $f : X \rightarrow Y$, значения которой известны только на объектах выборки $(\tilde{X}, \tilde{Y}) = \{(x_k, y_k), k = 1, \dots, N\}$.

Требуется построить алгоритм-оценку $\hat{f} : X \rightarrow Y$.

Векторизация

NiBabel — библиотека предоставляющая возможность читать различные форматы файлов нейровизуализации.




Рис.: Векторизация фМРТ данных.

Основная идея (Zaikin Alexey 2022)




Рис.: Классификация на основе построения графов отражающих входные данные.

Обозначения

Пусть $X = \{x_k\}_k$ — множество фМРТ, а $Y = \{y_k\}_k$ — режимы когнитивной активности $\{x_k\}_k$ со значениями I или II .

$x_k \in X$ конвертируется в массив a^k , на основе которого строится граф $g_k = (V_k, E_k, R_k, W_k)$, где

- $V_k = \{v_i^k\}_i$ — множество вершин,
- $E_k = \{e_{ij}^k\}_{ij}$ — множество неориентированных ребер,
- $R_k = \{r_i^k\}_i$ — множество значений вершин,
- $W_k = \{w_{ij}^k\}_{ij}$ — множество весов ребер,
- v_i^k — вершина отражающая область мозга i ,
- e_{ij}^k — ребро отражающее связь между областями i и j ,
- r_i^k — значение вершины v_i^k ,
- w_{ij}^k — вес ребра e_{ij}^k .

Подсчет весов ребер w_{ij}^k

Вероятностное определение w_{ij}^k

$$w_{ij}^k = P(y_k = II | r_i^k, r_j^k) - P(y_k = I | r_i^k, r_j^k)$$

Пусть $Cl_{ij} : \{y_k | (r_i^k, r_j^k), \{(r_i^n, r_j^n)\}_n, \{y_n\}_n\}_k \rightarrow [0, 1]$ — вероятностный классификатор.

Алгоритмическое определение w_{ij}^k

$$w_{ij}^k = Cl_{ij}(y_k = II | (r_i^k, r_j^k), \{(r_i^n, r_j^n)\}_n, \{y_n\}_n) - \\ - Cl_{ij}(y_k = I | (r_i^k, r_j^k), \{(r_i^n, r_j^n)\}_n, \{y_n\}_n)$$




Рис.: Эмпирическая плотность распределения (r_i, r_j) для двух режимов, вычисленная по $\{(r_i^n, r_j^n)\}_n$

Увеличение размеров вокселя

Увеличение размера шага решетки фМРТ в n раз уменьшает число вокселей в n^3 раза.




Рис.: Воксель 2 мм³




Рис.: Воксель 4 мм³




Рис.: Воксель 10 мм³

Понижение размерности по времени

Пусть T — некоторая статистика,

$$a^{kT} = T(a^k),$$

т.е. для $\forall x, y, z$

$$a_{xyz}^{kT} = T(\{a_{xyzt}^k : \forall t\}).$$




Рис.: Значения вокселя.

Смена структуры графа

Переход от полного графа к графу-решетке снижает время вычисления и требуемую память с $O(n^2)$ до $O(n)$, где n — число вершин графа.




Рис.: Переход от полного графа к графу-решетке.

Обучение модели

Входные данные:

- выборка (\tilde{X}, \tilde{Y}) ,
- новый размер шага решетки фМРТ s ,
- статистики вокселей $\{T_r\}_r$,
- минимальное абсолютное значение ребра w для которого ребро не удаляется из графа,
- статистики графов $\{P_u\}_u$, на которых будет учиться модель.

Обучение модели

Алгоритм:

- 1 изменение шага решетки фМРТ для $\forall x_k \in \tilde{X}$;
- 2 построение $\{a^k\}_k$;
- 3 подсчет $\{a^{kT_p}\}_{kp}$;
- 4 обучение $\{Cl_{ij}\}$ на выборке $(\{a^{kT_p}\}_{kp}, \tilde{Y})$;
- 5 подсчет $W_k = \{w_{ij}^k\}_{ij}$ с помощью $\{Cl_{ij}\}_{ij}$;
- 6 построение графов g_k с помощью a^{kT_p} и $\{w_{ij}^k\}$

Данные





Рис.: Разделение выборки.

Рис.: Наблюдение или воображение объекта.

Точность классификации, %

<i>mean</i>	<i>median</i>	<i>max</i>	<i>min</i>	<i>max – min</i>
100	100	95.7	97.1	90

<i>q_{0.9}</i>	<i>q_{0.1}</i>	<i>q_{0.9} – q_{0.1}</i>
98.6	100	88.6