

Синолитические сети в классификации мозговой активности

Власенко Даниил

Научные руководители: Заикин Алесей, Захаров Денис

8 марта 2023 г.

фМРТ

Определение

Функциональная магнитно-резонансная томография или фМРТ — разновидность магнитно-резонансной томографии, которая проводится с целью измерения изменений в токе крови, вызванных нейронной активностью головного мозга.



Рис.: фМРТ сканер.

фМРТ




Рис.: МРТ скан.

Цель работы

Будем считать, что мозг может функционировать в двух режимах.

Цель работы

Реализация и тестирование метода классификации режимов мозговой активности на основе фМРТ данных, в основе которого будут лежать синолитические сети..

Классификация

Вероятностная постановка задачи классификации

Пусть есть с.в. $\xi : \Omega \rightarrow X$ и с.в. $\eta : \Omega \rightarrow Y$. Рассмотрим с.в. $(\xi, \eta) : \Omega \rightarrow (X, Y)$ с распределением $p(x, y)$.

Задача классификации сводится к оценке $p(y|x)$ по выборке $(\tilde{X}, \tilde{Y}) = \{(x_n, y_n)\}_n$.

Алгоритмическая постановка задачи классификации

Пусть X — множество описаний объектов, Y — множество номеров классов. Существует функция $f : X \rightarrow Y$, значения которой известны только на объектах выборки $(\tilde{X}, \tilde{Y}) = \{(x_n, y_n)\}_n$.

Требуется построить алгоритм-оценку $\hat{f} : X \rightarrow Y$.

Векторизация

NiBabel — библиотека предоставляющая возможность читать различные форматы файлов нейровизуализации.




Рис.: Векторизация фМРТ данных.

Основная идея (Zaikin Alexey 2022)




Рис.: Классификация на основе построения графов отражающих входные данные.

Обозначения

Пусть X — множество фМРТ, а $Y = \{I, II\}$ — режимы когнитивной активности. $(\tilde{X}, \tilde{Y}) = \{(x_n, y_n)\}_n$ — конечная выборка из (X, Y) .

$x_k \in X$ конвертируется в массив a^k , на основе которого строится граф $g_k = (V_k, E_k, R_k, W_k)$, где

- $V_k = \{v_i^k\}_i$ — множество вершин,
- $E_k = \{e_{ij}^k\}_{ij}$ — множество неориентированных ребер,
- $R_k = \{r_i^k\}_i$ — множество значений вершин,
- $W_k = \{w_{ij}^k\}_{ij}$ — множество весов ребер,
- v_i^k — вершина, отражающая область мозга i ,
- e_{ij}^k — ребро, отражающее связь между областями i и j ,
- r_i^k — значение вершины v_i^k ,
- w_{ij}^k — вес ребра e_{ij}^k .

Подсчет весов ребер w_{ij}^k

Вероятностное определение w_{ij}^k

$$w_{ij}^k = P(y_k = II | r_i^k, r_j^k) - P(y_k = I | r_i^k, r_j^k)$$

Пусть $Cl_{ij} : \{y_k | (r_i^k, r_j^k), \{(r_i^n, r_j^n)\}_n, \{y_n\}_n\}_k \rightarrow [0, 1]$ — вероятностный классификатор.

Алгоритмическое определение w_{ij}^k

$$w_{ij}^k = Cl_{ij}(y_k = II | (r_i^k, r_j^k), \{(r_i^n, r_j^n)\}_n, \{y_n\}_n) - \\ - Cl_{ij}(y_k = I | (r_i^k, r_j^k), \{(r_i^n, r_j^n)\}_n, \{y_n\}_n)$$




Рис.: Эмпирическая плотность распределения (r_i, r_j) для двух режимов, вычисленная по $\{(r_i^n, r_j^n)\}_n$.

Увеличение размеров вокселя

Увеличение размера шага решетки фМРТ в n раз уменьшает число вокселей в n^3 раза.




Рис.: Воксель 2 мм³




Рис.: Воксель 4 мм³




Рис.: Воксель 10 мм³

Понижение размерности по времени

Пусть T — некоторая статистика,

$$a^{kT} = T(a^k),$$

т.е. для $\forall x, y, z$

$$a_{xyz}^{kT} = T(\{a_{xyzt}^k : \forall t\}).$$




Рис.: Значения вокселя.

Смена структуры графа

Построение вместо полного графа графа-сетки снижает время вычисления и требуемую память с $O(n^2)$ до $O(n)$, где n — число вершин графа.




Рис.: Смена структуры графа.

Обучение модели

Входные данные:

- выборка (\tilde{X}, \tilde{Y}) ,
- новый размер шага решетки фМРТ s ,
- статистики вокселей $\{T_m\}_m$,
- минимальное значение вершины r , для которого инцидентные с ним ребра не удаляются из графа,
- минимальное абсолютное значение ребра w , для которого ребро не удаляется из графа,
- характеристики графов $\{F_u\}_u$, на которых будет учиться модель.

Обучение модели

Алгоритм:

- ❶ изменение шага решетки фМРТ на s для $\forall x_n \in \tilde{X}$;
- ❷ построение $\{a^n\}_n$;
- ❸ вычисление $\{\{a^{nT_m}\}_m\}_n$;
- ❹ обучение $\{Cl_{ij}\}_{ij}$ на выборке $(\{\{a^{nT_m}\}_m\}_n, \tilde{Y})$;
- ❺ подсчет $\{W_n\}_n = \{\{w_{ij}^n\}_{ij}\}_n$ с помощью $\{Cl_{ij}\}_{ij}$ и $\{\{a^{nT_m}\}_m\}_n$;
- ❻ построение графов $\{g_n\}_n$;
- ❼ удаление ребер $\{e_{ij}^n : r_i^n < r | r_j^n < r | w_{ij}^n < w\}_{ij}$ для $\forall g_n$;
- ❽ вычисление $\{\{f_u^n\}_u\}_n = \{\{F_u(g_n)\}_u\}_n$;
- ❾ обучение Cl на выборке $\{\{f_u^n\}_u\}_n$.

Классификация

Входные данные:

- фМРТ x_k .

Алгоритм:

- 1 изменение шага фМРТ x_k решетки на s ;
- 2 построение a^k ;
- 3 вычисление $\{a^{kT_m}\}_m$;
- 4 подсчет $W_k = \{w_{ij}^k\}_{ij}$ с помощью $\{Cl_{ij}\}_{ij}$ и $\{a^{kT_m}\}_m$;
- 5 построение графа g_k ;
- 6 удаление из g_k ребер $\{e_{ij}^k : r_i^k < r | r_j^k < r | w_{ij}^k < w\}_{ij}$;
- 7 вычисление $\{f_u^k\}_u = \{F_u(g)\}_u$;
- 8 классификация $\{f_u^k\}_u$ с помощью Cl .

Данные




Рис.: Наблюдение или воображение объекта.

Данные

	seen		imagined		
	training	test	training	test	
sub-01	17	7	14	6	44
sub-02	17	7	14	6	44
sub-03	17	7	14	6	44
sub-04	17	7	14	6	44
sub-05	16	8	14	6	44
	84	36	70	30	220
	120		100		

Таблица: Разделение выборки.

Характеристики графов



Рис.: Распределения некоторых характеристик графов при $\{T_i\}_{i=T_1}$, где T_1 — среднее значение вокселя.

Характеристики графов

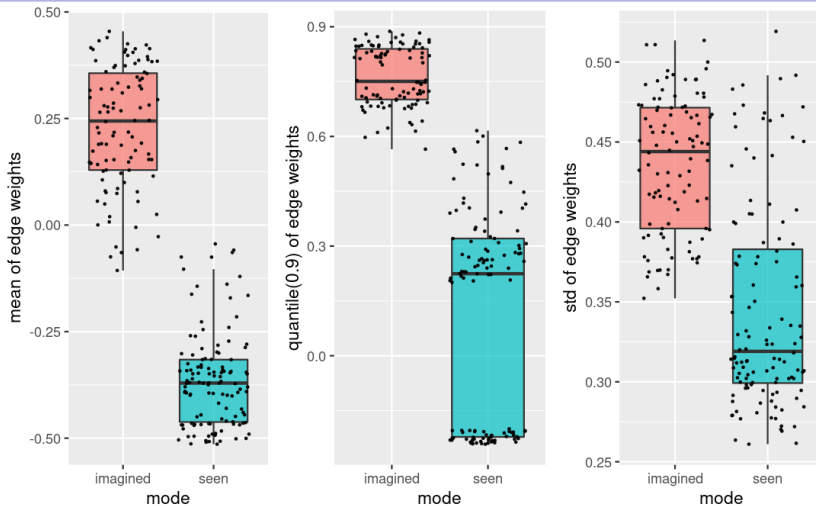


Рис.: Распределения некоторых характеристик графов при $\{T_i\}_i = T_1$, где T_1 — среднее значение вокселя.

Матрицы классификации

	seen	imagined
seen	32	4
imagined	0	30

Таблица: $\{T_m\}_m = T_1 = \text{mean}$,
точность 93.9%.

	seen	imagined
seen	32	4
imagined	1	29

Таблица: $\{T_m\}_m = T_1 = \text{min}$,
точность 90.9%.

	seen	imagined
seen	34	2
imagined	1	29

Таблица: $\{T_m\}_m = T_1 = \text{quantile}(0.9) - \text{quantile}(0.1)$, точность 95.5%.